Compilação de Resultados — TCC

Engenharia de Contexto para Agentes de IA:
Adoção, Sobreposição e Estrutura de Arquivos de Contexto em Repositórios Open Source

Documento de compilação bruta de gráficos, tabelas e resultados numéricos gerados nos notebooks do repositório, com ênfase em **RQ01** (sobreposição de múltiplos arquivos de contexto) e **RQ02** (estrutura/classificação de conteúdo), para uso como material de apoio na redação da seção de Resultados e Discussão.

Sumário

- 0. Dados de Base e Metodologia de Coleta
- 1. Adesão a Arquivos de Contexto de IA (base motivacional da RQ01)
- 2. RQ01 — Sobreposição Lexical e Semântica em Múltiplos Arquivos de Contexto de IA
  - 2.1 Diagnóstico Quantitativo em Escala (1.238 repositórios)
  - 2.2 Análise Lexical e Semântica Par-a-Par (via LLM)
- 3. RQ02 — Estrutura e Classificação de Conteúdo dos Arquivos de Contexto
- 4. Validação de Fidelidade das Instruções de Teste (apoio à RQ02)
- 5. Comparação Temporal de Adesão (pendente)

0. Dados de Base e Metodologia de Coleta

Fontes: notebooks 1-seart_data_study.ipynb e 2-ranking_data_study.ipynb

> **Contexto para a IA que vai redigir o texto:** esta seção documenta a origem dos dados (ferramenta SEART, coleta de metadados de repositórios GitHub) e o processo de ranqueamento (popularidade + maturidade, com penalidades para detectar inflação artificial de estrelas/forks). Não é uma seção de "resultados" propriamente dita, mas fundamenta a amostragem usada em todas as RQs. Usar como base do texto de "Metodologia" / "Materiais e Métodos", não de "Resultados".

Estudos sobre os dados fornecidos pelo SEART_DATA

Este notebook tem como objetivo analisar os dados, dos repositórios github, fornecidos pela ferramenta SEART.

Importação de bibliotecas

Análise das colunas dos dados

Escolhendo JSON para análise

```
Selected file: ../data/seart_data/23-03-2026.json
```

Criação de dataframe para análise

Descrição de cada coluna existente:

Identificação e metadados básicos: - id: Identificador numérico interno único do repositório no banco de dados do SEART. - name: Nome completo do repositório no formato usuário/nome-do-projeto. - isFork: Valor booleano que indica se o repositório é um fork (cópia) de outro projeto. - mainLanguage: A linguagem de programação principal detectada no repositório. - defaultBranch: O nome da branch padrão do projeto (geralmente main ou master). - license: O nome da licença de código aberto aplicada ao projeto (ex: MIT, Apache 2.0). - homepage: URL do site oficial ou documentação do projeto, se fornecida.

Métricas de atividade e popularidade: - commits: Número total de commits realizados na branch padrão. - branches: Quantidade total de branches existentes no repositório. - releases: Número de versões publicadas. - forks: Quantidade de vezes que o repositório foi "forkado" por outros usuários. - watchers: Número de usuários que estão "observando" o projeto para receber notificações. - stargazers: Número total de estrelas que o projeto recebeu de usuários do GitHub.

Datas e temporalidade: - createdAt: Data e hora em que o repositório foi criado. - pushedAt: Data e hora do último "push" para qualquer branch. [REVIZAR] - updatedAt: Data e hora da última modificação nos metadados do repositório. - lastCommit: Data e hora exata do commit mais recente na branch padrão. - lastCommitSHA: O hash do último commit realizado.

Gestão de problemas e colaboração: - totalIssues: Soma total de issues criadas. - openIssues: Número de issues abertas. - totalPullRequests: Soma total de pull requests. - openPullRequests: Número de

pull requests abertos. - contributors: Quantidade de usuários únicos que contribuíram com código para o projeto.

Métricas de código: - blankLines: Quantidade total de linhas em branco nos arquivos de código. - codeLines: Quantidade total de linhas de código. - commentLines: Quantidade total de linhas de comentário. - metrics: Objeto ou lista contendo métricas detalhadas por linguagem (complexidade, linhas, etc.). [REVIZAR] - size: Tamanho total do repositório.

Status e configurações: - hasWiki: Booleano que indica se o projeto tem a funcionalidade de Wiki ativa. - isArchived: Indica se o repositório foi arquivado. - isDisabled: Indica se o repositório foi desativado. - isLocked: Indica se o repositório está bloqueado.

Listas e tags: - languages: Dicionário com todas as linguagens detectadas e a quantidade de bytes de cada uma. - labels: Lista de etiquetas utilizadas no projeto. - topics: Lista de palavras-chave que categorizam o projeto.

```
['id', 'name', 'isFork', 'commits', 'branches', 'releases', 'forks', 'mainLanguage',
'defaultBranch', 'license', 'homepage', 'watchers', 'stargazers', 'contributors', 'size',
'createdAt', 'pushedAt', 'updatedAt', 'totalIssues', 'openIssues', 'totalPullRequests',
'openPullRequests', 'blankLines', 'codeLines', 'commentLines', 'metrics', 'lastCommit',
'lastCommitSHA', 'hasWiki', 'isArchived', 'isDisabled', 'isLocked', 'languages', 'labels',
'topics']
```

Ideias de análises

- Distribuição de linguagens mais comuns em repositórios que utilizam arquivos do tipo agents.md. Comparar essa distribuição com a de projetos que não utilizam, e comparar com a distribuição genérica dos repositórios;
- Comparativo de distribuição de projetos entre (Possuir arquivos agents.md) X (Possuir wiki ativa do projeto).

Estudos sobre os dados ranqueados

Este notebook tem como objetivo analisar a estrutura dos arquivos gerados pelo ranqueamento da listagem dos repositórios listados em `/data/seart_data/*`, gerando assim arquivos do tipo `ranked_DD-MM-YYYY.csv`

Importação de bibliotecas

Seleção de arquivo para análise

```
Selected file: ../data/output_rankings/ranked_23-03-2026.csv
```

Criação do dataframe

```
['projectAge',
 'normalized_stargazers',
 'normalized_contributors',
 'normalized_watchers',
 'popularity_score',
```

```
'normalized_projectAge',
'normalized_commits',
'normalized_codeLines',
'maturity_score',
'stars_to_commits',
'stars_commits_penalty',
'text_percentage',
'text_penalty',
'forks_to_stars',
'forks_stars_penalty',
'forks_to_codeLines',
'forks_codelines_penalty',
'popularity_score_pen',
'maturity_score_pen',
'rank_score',
'rank']
```

Descrição das colunas de ranqueamento [REVIZAR]

Além das colunas originais do SEART, o processo de ranqueamento adiciona métricas calculadas e normalizadas:

Métricas de Popularidade

- `normalized_stargazers`: Número de estrelas normalizado.
- `normalized_contributors`: Número de contribuidores normalizado.
- `normalized_watchers`: Número de watchers normalizado.
- `popularity_score`: Pontuação combinada de popularidade (média ponderada das métricas normalizadas).

Métricas de Maturidade

- `projectAge`: Idade do projeto em dias.
- `normalized_projectAge`: Idade do projeto normalizada.
- `normalized_commits`: Número de commits normalizado.
- `normalized_codeLines`: Número de linhas de código normalizado.
- `maturity_score`: Pontuação combinada de maturidade.

Penalidades e Ajustes

- `stars_to_commits`: Razão entre estrelas e commits.
- `stars_commits_penalty`: Penalidade aplicada se a razão estrelas/commits for muito alta (indicando possível inflação artificial de estrelas).
- `text_percentage`: Porcentagem de arquivos de texto/documentação.
- `text_penalty`: Penalidade baseada na proporção de documentação vs código.
- `forks_to_stars`: Razão entre forks e estrelas.
- `forks_stars_penalty`: Penalidade baseada na razão forks/estrelas.
- `forks_to_codeLines`: Razão entre forks e linhas de código.

- `forks_codelines_penalty`: Penalidade baseada na razão forks/linhas de código (ajuda a identificar repositórios de tutoriais).
- `popularity_score_pen`: Pontuação de popularidade ajustada após a aplicação das penalidades de estrelas e forks.
- `maturity_score_pen`: Pontuação de maturidade ajustada após a aplicação das penalidades de texto e linhas de código.

Resultado Final

- `rank_score`: Pontuação final combinada (Popularidade + Maturidade com penalidades).
- `rank`: A posição final do repositório no ranking.

1. Adesão a Arquivos de Contexto de IA (base motivacional da RQ01)

Fonte: notebooks/3-context-ai-repo-study.ipynb — amostra Top 1000 (23-03-2026)

> **Contexto:** esta análise responde "quantos repositórios adotam arquivos de contexto de IA e com que frequência adotam mais de um simultaneamente?". É a evidência preliminar/motivacional que dá origem à RQ01 (o README da RQ01 cita este notebook explicitamente como "análise preliminar de adesão"). Destaques numéricos: proporção geral de adoção, adoção por faixa de rank, distribuição da quantidade de arquivos por repositório (fundamental para justificar o recorte de "2+ arquivos" da RQ01), combinações mais comuns (ex.: AGENTS.md + CLAUDE.md + COPILOT) e frequência isolada por tipo de arquivo.

Estudos de adesão de arquivos de contexto de IA

Este notebook tem como objetivo analisar a presença de arquivos de contexto de IA (como `AGENTS.md`, `CLAUDE.md`, etc.) nos repositórios ranqueados. Os dados foram coletados via API do GitHub.

Configurações

Importações

Setup de visualização

Estudo da estrutura dos dados

Nesta seção, analisamos a estrutura do arquivo gerado pela detecção de arquivos de contexto.

```
Colunas encontradas: ['name', 'rank', 'AGENTS.md', 'CLAUDE.md', 'COPILOT', 'GEMINI.md',
'CURSOR']
```

	name	rank	AGENTS.md	CLAUDE.md	COPILOT	GEMINI.md	CURSOR
0	rust-lang/rust	1.0	0	0	0	0	0

	name	rank	AGENTS.md	CLAUDE.md	COPILOT	GEMINI.md	CURSOR
1	tensorflow/tensorflow	2.0	0	0	0	0	0
2	elastic/elasticsearch	3.0	1	0	0	0	0
3	git/git	4.0	0	0	0	0	0
4	kubernetes/kubernetes	5.0	0	0	0	0	0

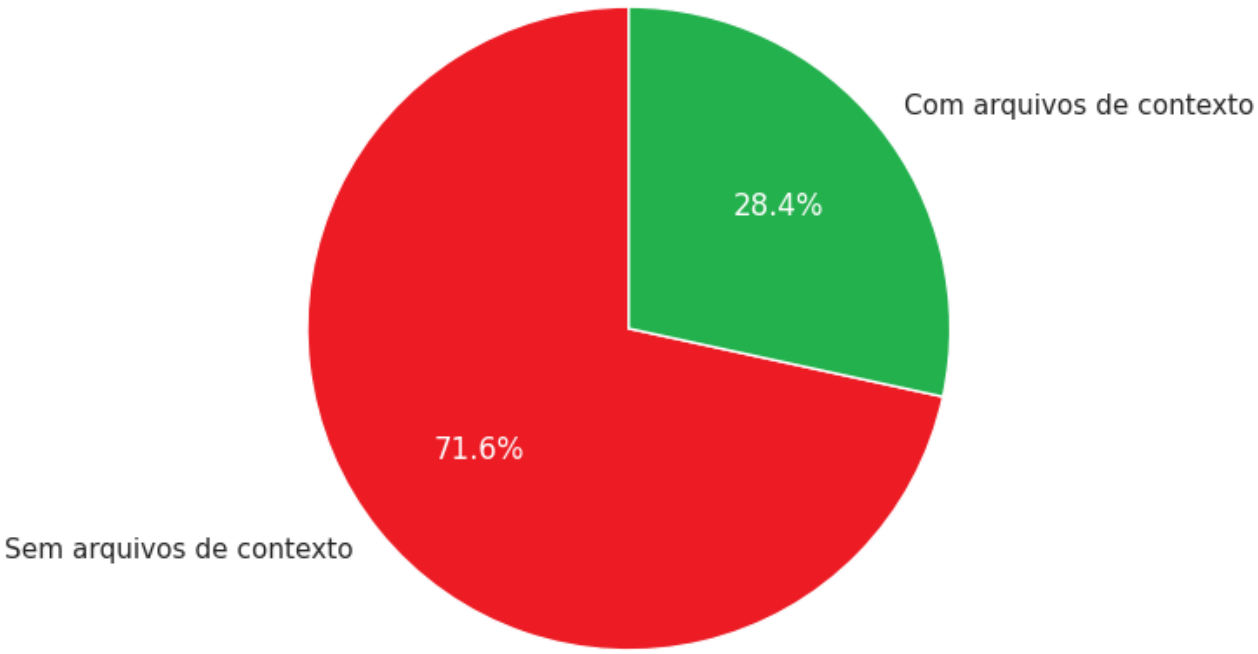
Descrição das colunas

- `name`: Nome do repositório (usuário/projeto).
- `rank`: Posição do repositório no ranking de popularidade/maturidade.
- `AGENTS.md`: Indica se o arquivo `AGENTS.md` foi detectado (1) ou não (0).
- `CLAUDE.md`: Indica se o arquivo `CLAUDE.md` foi detectado (1) ou não (0).
- `COPILOT`: Indica se arquivos de configuração do GitHub Copilot foram detectados.
- `GEMINI.md`: Indica se o arquivo `GEMINI.md` foi detectado (1) ou não (0).
- `CURSOR`: Indica se arquivos de configuração do Cursor foram detectados.

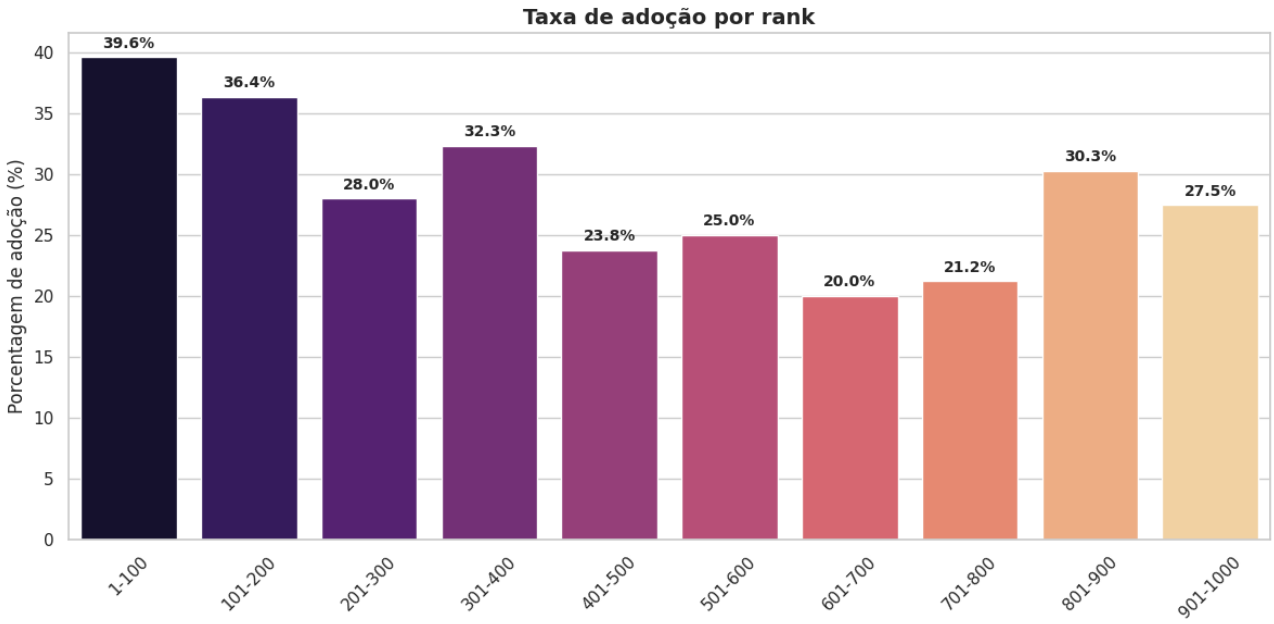
Análise de adesão

Configurando o dataframe

Verificação de proporção de arquivos de contexto de IA nos repositórios

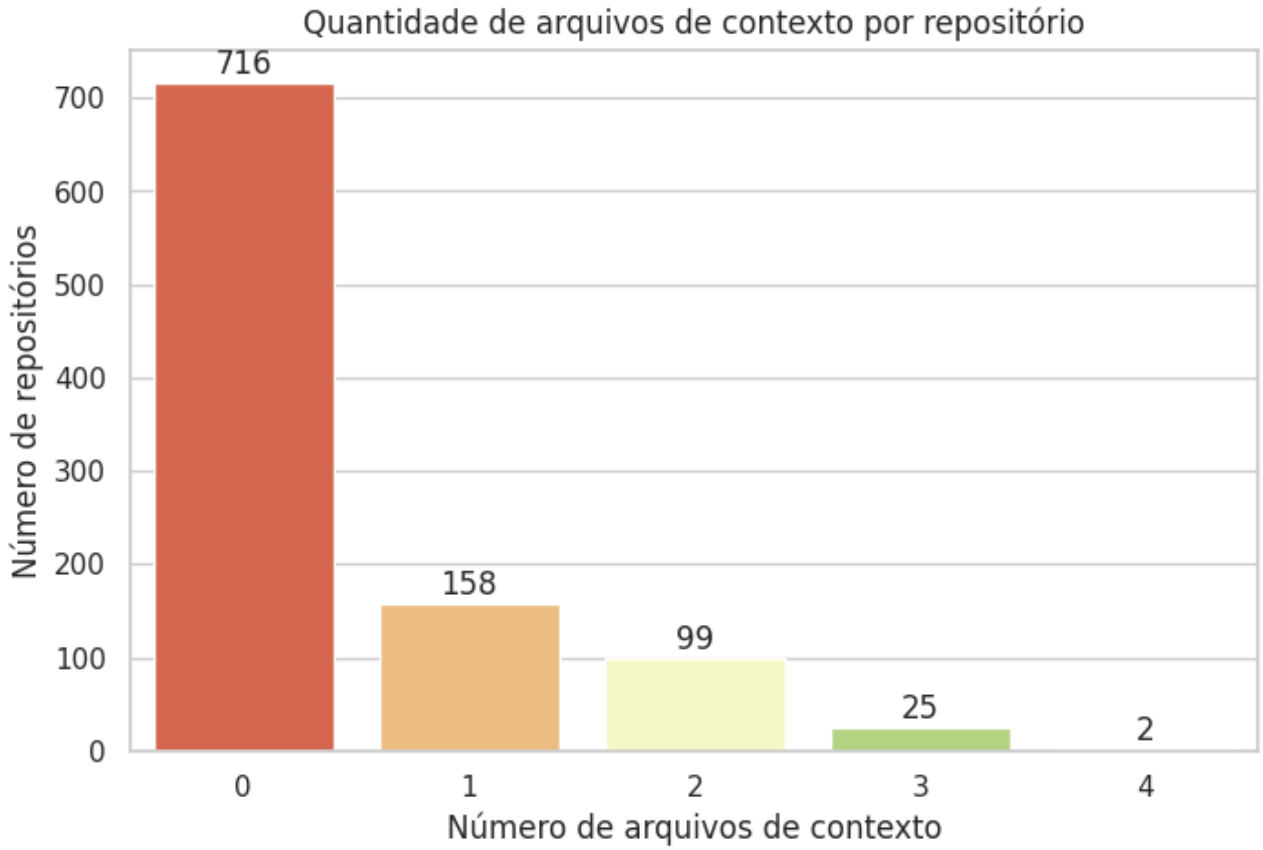


Adoção por Faixa de Rank



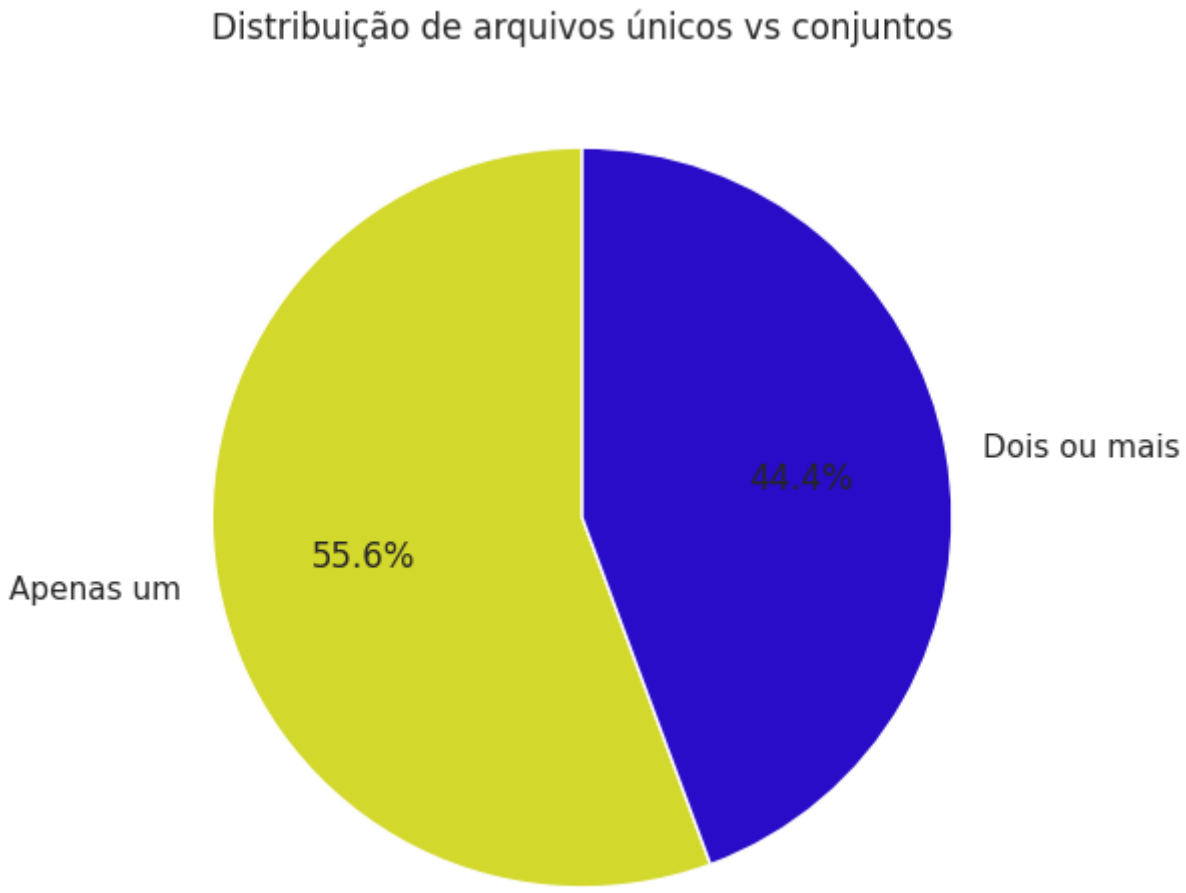
Quantidade de arquivos por repositório

Criação de coluna para contagem de arquivos de contexto por repositório



Análise de arquivos de contexto conjuntos

Distribuição entre os arquivos únicos e compostos

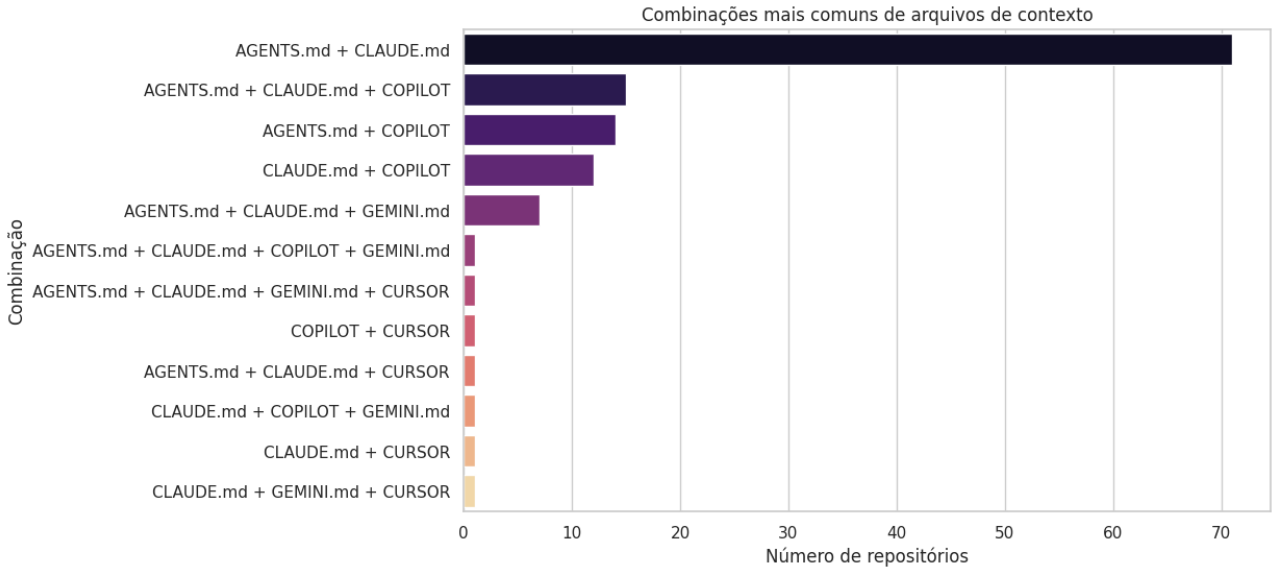


Arquivos de contexto descritos por repositório

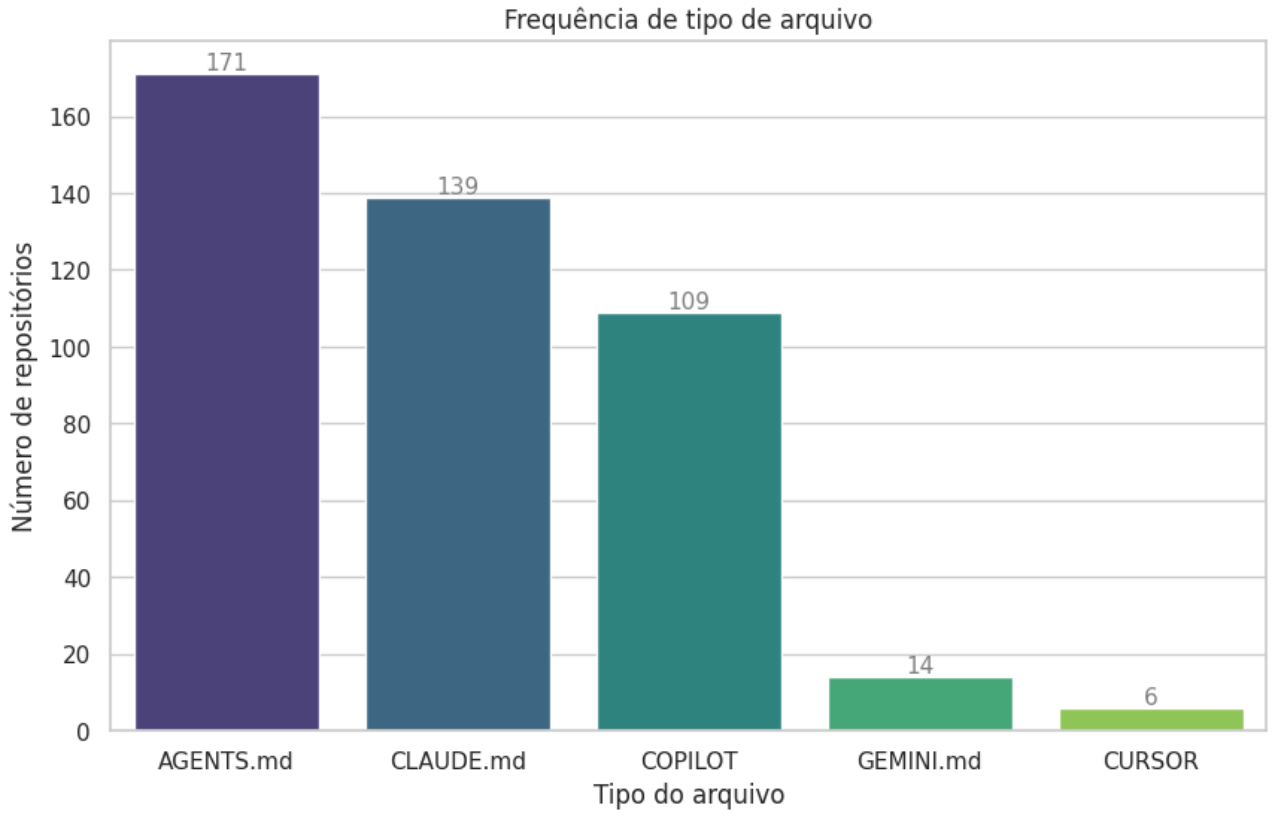
```
Total de repositórios com dois ou mais arquivos: 126
```

	name	combination	context_count
58	apache/superset	AGENTS.md + CLAUDE.md + COPILOT + GEMINI.md	4
341	apache/grails-core	AGENTS.md + CLAUDE.md + GEMINI.md + CURSOR	4
88	huggingface/transformers	AGENTS.md + CLAUDE.md + COPILOT	3
122	vitessio/vitess	AGENTS.md + CLAUDE.md + COPILOT	3
59	seleniumhq/selenium	AGENTS.md + CLAUDE.md + COPILOT	3
11	home-assistant/core	AGENTS.md + CLAUDE.md + COPILOT	3
230	spinnaker/spinnaker	AGENTS.md + CLAUDE.md + COPILOT	3
306	mapbox/mapbox-gl-js	AGENTS.md + CLAUDE.md + GEMINI.md	3
365	internetarchive/openlibrary	AGENTS.md + CLAUDE.md + COPILOT	3
361	mautic/mautic	AGENTS.md + CLAUDE.md + GEMINI.md	3

Quantidade de repositório por composição de arquivos de IA



Frequência por tipo de arquivo



2. RQ01 — Sobreposição Lexical e Semântica em Múltiplos Arquivos de Contexto de IA

Questão de pesquisa: qual é o grau de sobreposição lexical e semântica de diretrizes em repositórios que mantêm múltiplos arquivos de contexto para diferentes agentes de IA?

2.1 Diagnóstico Quantitativo em Escala (1.238 repositórios, sem LLM)

Fonte: notebooks/7-repo_level_category_study.ipynb — snapshot Top 10.000 (24-08-2025)

> **Contexto:** complementa a RQ01 em escala total (1.238 repositórios com pelo menos 1 arquivo de contexto, contra os 266 usados na classificação por heading/LLM). Usa classificação por regex de categorias de conteúdo (sem LLM) para testar quantitativamente se repositórios com mais arquivos de contexto cobrem mais categorias distintas (indício de especialização) ou ficam restritos às mesmas poucas categorias (indício de redundância) — teste direto e independente da H1 da RQ01. Inclui também uma nota de limitação metodológica relevante sobre os 12 outliers com zero headings extraídos (arquivos sem heading Markdown ATX, ex. listas de bullets ou ponteiros tipo `@AGENTS.md`).

Análise de Categorias de Conteúdo por Repositório (Escala Completa)

Este notebook analisa o `regex_analysis_content_ai_context_files.csv`, gerado por `scripts/regex_analysis_content.py` a partir dos arquivos de contexto de IA baixados por `scripts/download_ai_context_files.py`.

Diferente de `4-structure_analysis_study.ipynb` e `5-ai-file-classification-study.ipynb` (que analisam dados em formato longo, um *heading* por linha, cobrindo 266 repositórios do snapshot Top 1000/23-03-2026), aqui os dados estão em formato largo (uma linha por repositório, booleano por categoria) e cobrem **1.238 repositórios** do snapshot completo Top 10.000/24-08-2025 — todos os repositórios que possuem ao menos 1 arquivo de contexto de IA.

Objetivo: gerar um primeiro diagnóstico quantitativo de conteúdo em escala total, complementando a análise semântica via LLM já em andamento na RQ01.

Configurações

Carregamento dos dados

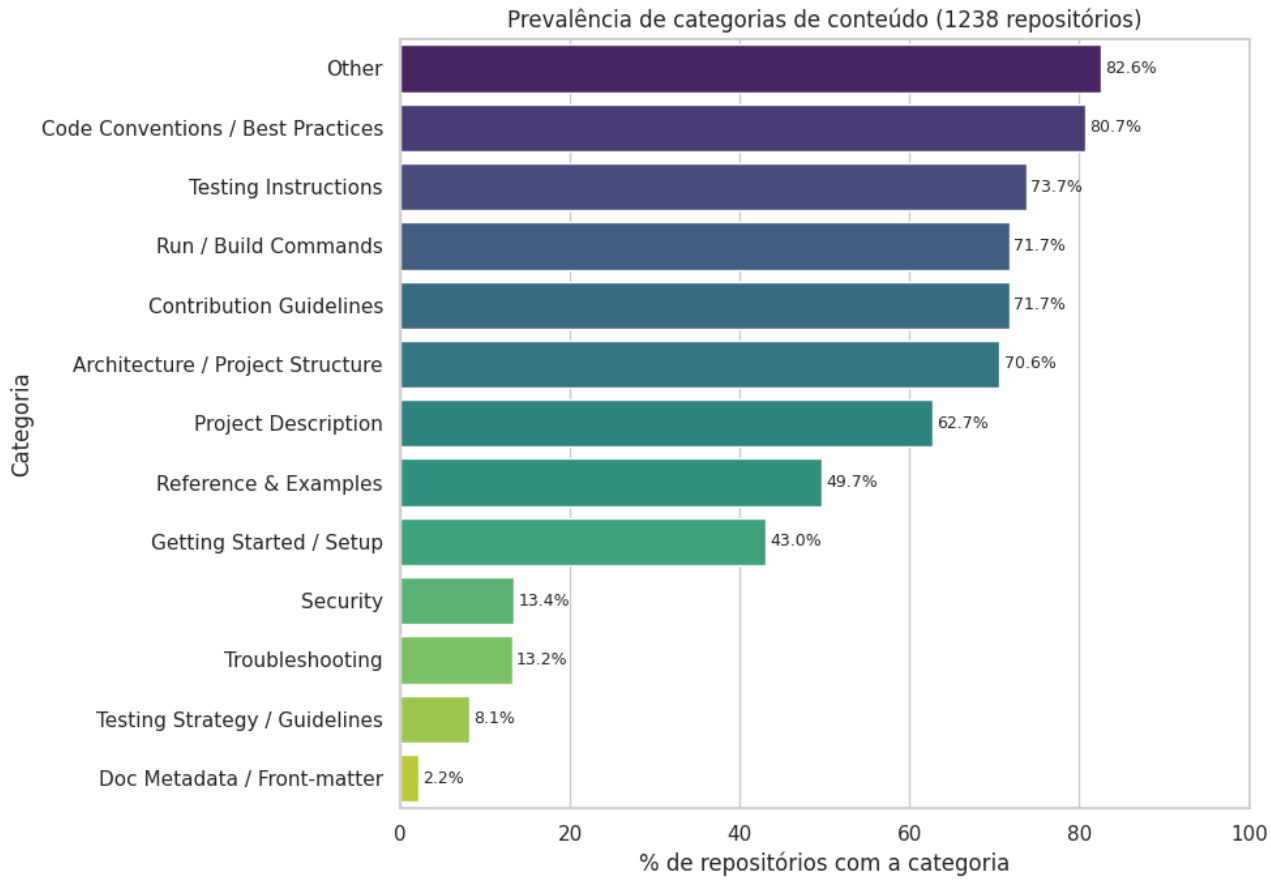
```
Total de repositórios: 1238
Categorias monitoradas: 13
```

	repo	Testing Strategy / Guidelines	Testing Instructions	Architecture / Project Structure	Code Conventions / Best Practices	Contribution Guidelines	Getting Started / Setup	Run / Build Commands	Project Description	Tr
0	https://github.com/1technophile/openmqttgateway	False	True	True	True	True	True	True	True	Fa
1	https://github.com/ACINQ/eclair	False	True	True	True	True	True	True	True	Fa
2		False	True	False	True	False	False	False	False	Fa

	repo	Testing Strategy / Guidelines	Testing Instructions	Architecture / Project Structure	Code Conventions / Best Practices	Contribution Guidelines	Getting Started / Setup	Run / Build Commands	Project Description	Tr
	https://github.com/AleoNet/snarkOS									
3	https://github.com/Azure/Azure-Sentinel	False	False	True	True	True	False	True	False	Fa
4	https://github.com/Checkmk/checkmk	False	True	False	True	True	False	False	True	Fa

1. Prevalência de categorias

Em quantos por cento dos 1.238 repositórios cada categoria de conteúdo aparece (em pelo menos um dos arquivos de contexto de IA do repositório)?




```
Other                                82.552504
Code Conventions / Best Practices    80.694669
Testing Instructions                 73.747981
Run / Build Commands                 71.728595
Contribution Guidelines              71.728595
Architecture / Project Structure     70.597738
Project Description                  62.681745
```

```
Reference & Examples                  49.676898
Getting Started / Setup               42.972536
Security                              13.408724
Troubleshooting                       13.166397
Testing Strategy / Guidelines          8.077544
Doc Metadata / Front-matter            2.180937
dtype: float64
```

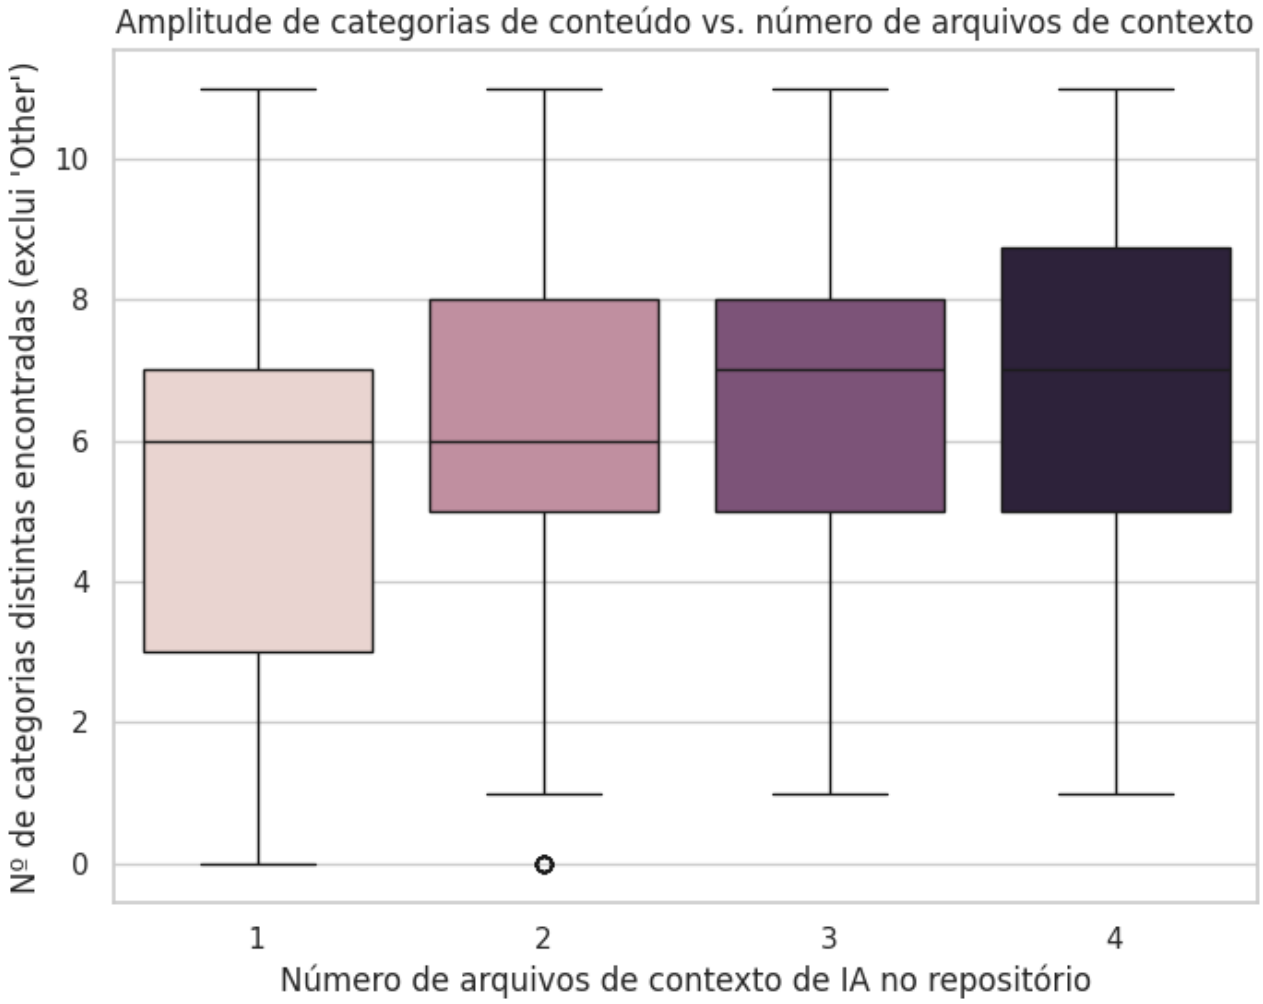
2. Amplitude de categorias vs. número de arquivos de contexto

Teste quantitativo (sem depender de LLM) da hipótese H1 da RQ01: repositórios com **mais arquivos de contexto** cobrem, em média, **mais categorias distintas** (indício de especialização) ou ficam restritos às mesmas poucas categorias (indício de redundância)?

A categoria `Other` é excluída do cálculo de amplitude por ser um bucket residual, não um tópico de conteúdo real.

```
Repositórios sem correspondência no manifesto: 0
```

	count	mean	median	std
qtd_arquivos_contexto				
1	761	5.203679	6.0	2.639136
2	374	6.120321	6.0	2.350966
3	93	6.741935	7.0	2.230730
4	10	6.500000	7.0	3.274480



Identificação dos outliers do boxplot acima

Usamos a mesma regra que o `seaborn.boxplot` usa para desenhar pontos soltos: outlier é todo valor fora de `[Q1 − 1,5×IQR, Q3 + 1,5×IQR]`, calculado **dentro de cada grupo** de `qtd_arquivos_contexto`.

```
Total de outliers encontrados: 12
```

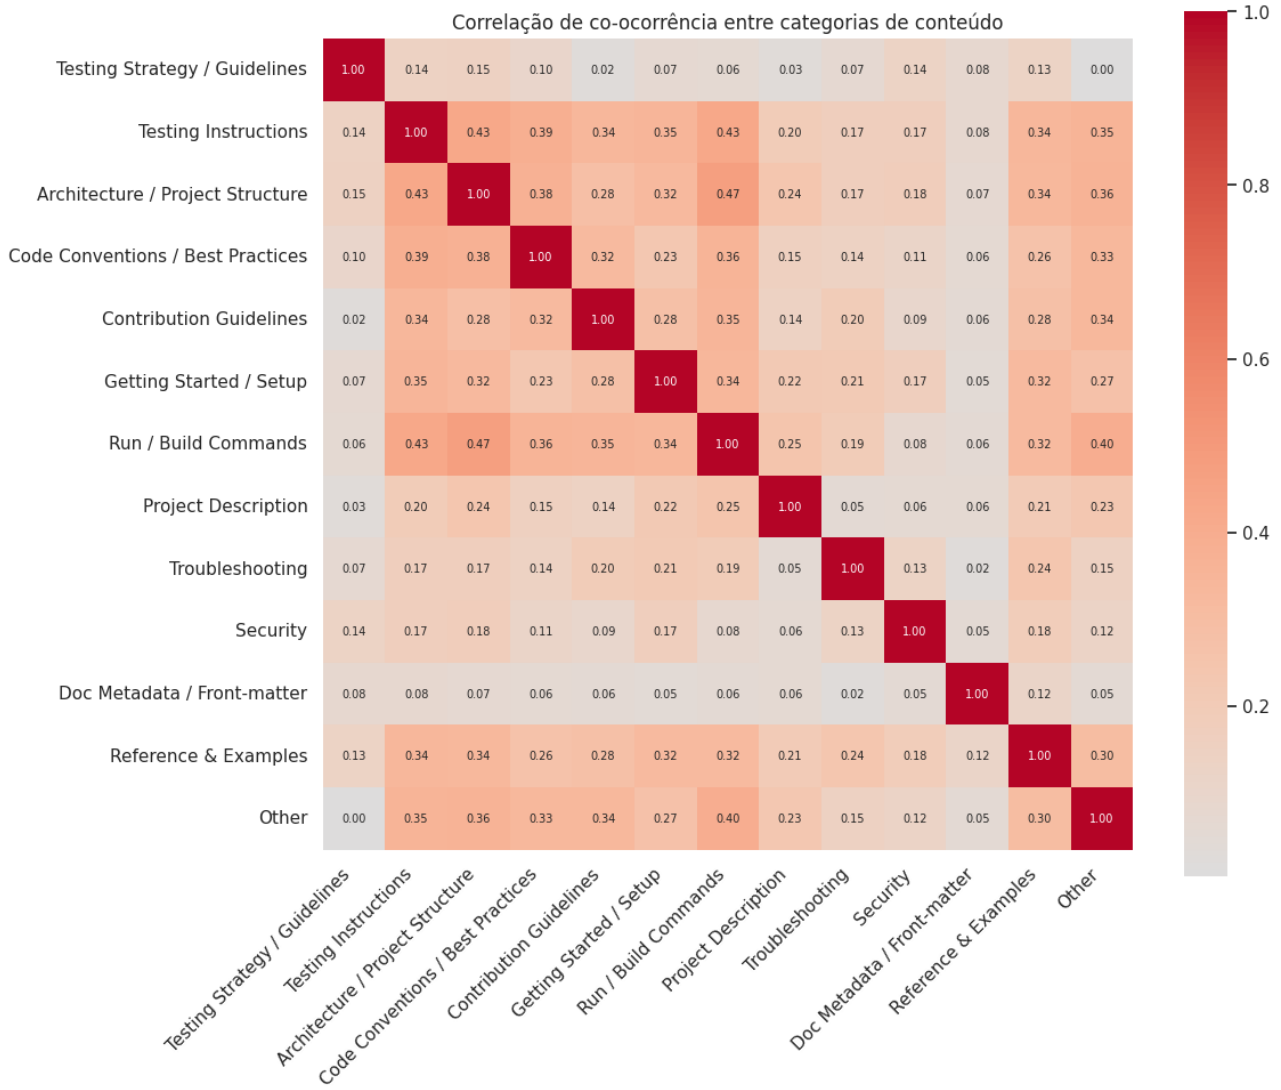
	repo	grupo_qtd_arquivos_contexto	qtd_categorias_significativas
92	https://github.com/astral-sh/uv	2	0
111	https://github.com/azure/azure-container-netwo...	2	0
405	https://github.com/fluentassertions/fluentasse...	2	0
457	https://github.com/go-gitea/gitea	2	0
468	https://github.com/gohugoio/hugo	2	0
571	https://github.com/jazzband/django-oauth-toolkit	2	0
581	https://github.com/jihong88/suneditor	2	0
589	https://github.com/johnbillion/query-monitor	2	0
651	https://github.com/libsdl-org/sdl	2	0
852	https://github.com/openbao/openbao	2	0

	repo	grupo_qtd_arquivos_contexto	qtd_categorias_significativas
1093	https://github.com/starkware-libs/cairo	2	0
1169	https://github.com/umijs/umi	2	0

Causa raiz (verificada manualmente em `astral-sh/uv`): os 12 outliers do grupo de 2 arquivos têm `qtd_categorias_significativas = 0` porque seus arquivos de contexto não usam headings Markdown (`#`) — por exemplo, `AGENTS.md` é uma lista de bullets sem heading, e `CLAUDE.md` contém só `@AGENTS.md` (um ponteiro/redirecionamento). Como `extract_headings_with_levels` só captura o estilo ATX (`# Título`), esses repositórios ficam com zero headings extraídos — mesmo tendo conteúdo real nas regras. Isso é uma **limitação metodológica do regex**, não um erro de coleta, e vale registrar como limitação no texto do TCC.

3. Co-ocorrência de categorias

Quais categorias tendem a aparecer juntas no mesmo repositório? Correlação (coeficiente phi, via `.corr()` sobre colunas booleanas 0/1) entre cada par de categorias.



Observações e limitações

- A classificação de categoria é feita por correspondência de palavras-chave (regex) sobre o título dos *headings* — não há validação semântica humana ou via LLM nesta etapa (diferente da análise par-a-par da RQ01).
- A categoria `Other` foi excluída do cálculo de amplitude por ser um bucket residual, não um tópico de conteúdo real.
- Esses resultados são quantitativos e em escala completa (1.238 repositórios), complementando — mas não substituindo — a validação manual e a análise semântica via LLM já em andamento na RQ01.

2.2 Análise Lexical e Semântica Par-a-Par (via LLM)

Fonte: notebooks/research_questions/rq01/notebook.ipynb + semantic_analysis_rq01.csv

> **Contexto:** a RQ01 pergunta qual é o grau de sobreposição lexical e semântica de diretrizes em repositórios que mantêm 2+ arquivos de contexto de IA simultaneamente, testando a Hipótese H1 (multiplicidade de arquivos reflete falta de padronização/duplicação de esforço, não especialização real).
>
> **Aviso metodológico importante:** o notebook de origem (`notebooks/research_questions/rq01/notebook.ipynb`) está em estado *parcialmente inacabado*: contém células duplicadas, uma execução interrompida (`KeyboardInterrupt`) e células com erro (`NameError` , `KeyError`) resultantes de tentativas anteriores com nomes de variável divergentes. Os trechos abaixo foram filtrados para incluir apenas os resultados que de fato foram produzidos com sucesso. Adicionalmente, o print de contagem exibido logo abaixo do gráfico de dispersão (filtragem por limiar P35) contém um bug de comparação de string no notebook original (compara com o literal `'Par válido)'` , com parêntese sobrando, em vez de `'Par válido'`), fazendo o notebook reportar "0 pares válidos" ali — por isso esse número foi omitido aqui. A contagem correta e confiável de pares com conteúdo relevante nos dois arquivos (mesmo limiar de 92,95 caracteres, calculado corretamente por comparação numérica) é a exibida logo em seguida: **262 pares**, envolvendo **205 repositórios únicos**. O resultado final e mais confiável desta análise está consolidado no arquivo `notebooks/research_questions/rq01/semantic_analysis_rq01.csv` (185 pares de arquivos classificados por um LLM local — qwen2.5:7b via Ollama — em 4 categorias: Redundantes, Complementares, Conflitantes, Independentes), cujo resumo estatístico está na tabela abaixo (calculado à parte, pois o próprio notebook não chegou a exibir esse resumo devido aos erros mencionados).

Distribuição das classificações semânticas (LLM local, n=185 pares de arquivos, 205 repositórios únicos)

Classificação	Nº de pares	% do total	Similaridade média (0-100)
Complementares	95	51,35%	74,3
Redundantes	36	19,46%	74,0
Redundantes | Complementares (misto)	27	14,59%	76,7
Conflitantes	13	7,03%	73,8
Independentes	4	2,16%	80,5
Conflitantes | Independentes (misto)	4	2,16%	77,5
Complementares | Independentes (misto)	4	2,16%	72,5
Outras combinações mistas	2	1,08%	80,0

Métrica `similaridade_semantica`: score 0-100 atribuído pelo LLM à sobreposição textual entre o par de arquivos (não confundir com o índice de posição no ranking). Média geral: 74,8 (desvio-padrão 9,0). Pares mais frequentemente comparados: AGENTS.md↔COPILOT (75), CLAUDE.md↔COPILOT (45), AGENTS.md↔CLAUDE.md (40).

RQ01: Qual é o grau de sobreposição lexical e semântica de diretrizes em repositórios de código aberto que mantêm múltiplos arquivos de contexto para diferentes agentes de IA?

Este notebook foca em repositórios que adotam **dois ou mais** arquivos de contexto de IA simultaneamente. O objetivo é entender se existe uma hierarquia, redundância ou se cada arquivo serve a um propósito específico.

Configurações

Casos específicos

Estudando repositórios com pelo menos 2 arquivos de contexto de IA

```
487
```

Análise de semelhança (Overlap de conteúdo)

Para os repositórios com alta densidade (2+), vamos buscar o conteúdo desses arquivos e calcular a similaridade de texto usando `SequenceMatcher`.

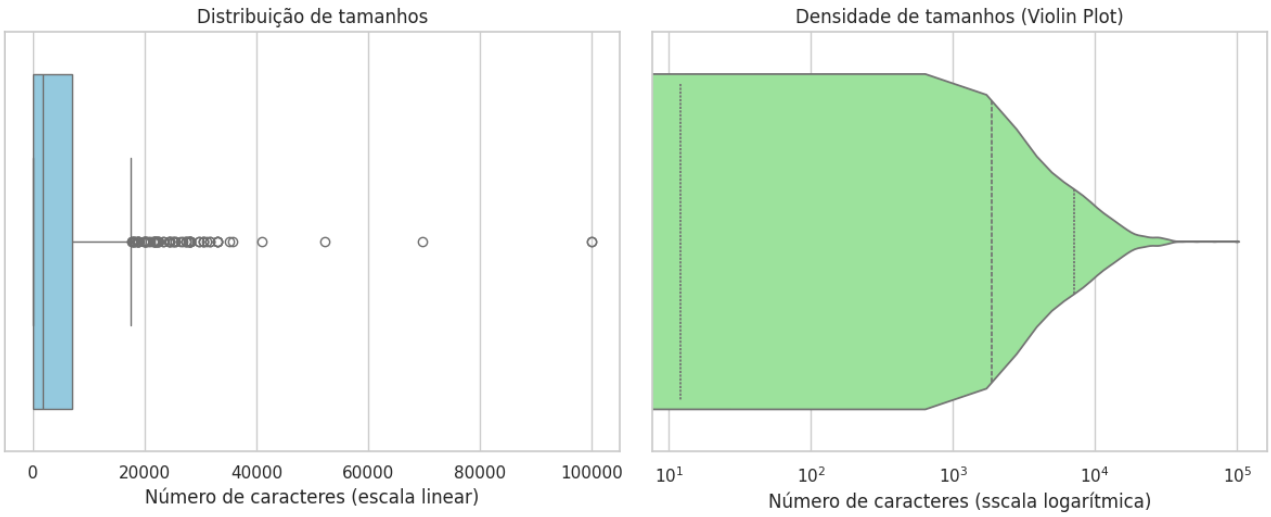
Fundamentação Estatística dos Limiares (Eliminando Números Mágicos)

Para evitar o uso de limiares arbitrários (números mágicos), analisamos a distribuição de probabilidade do tamanho dos arquivos e da similaridade léxica.

Utilizaremos o **Primeiro Quartil (Q1)** da distribuição de comprimento como o limite inferior de "conteúdo relevante". Arquivos abaixo de Q1 são estatisticamente tratados como ruído ou apenas ponteiros (redirecionamentos).

```
count     1338.000000
mean      4874.903587
std       7818.117327
min          6.000000
25%         12.000000
50%       1878.000000
75%       7082.750000
max      99969.000000
dtype: float64
--- Estatísticas de Comprimento (Caracteres) ---
Q1 (25%): 12.00 caracteres
P35 (35%): 92.95 caracteres
Mediana: 1878.00 caracteres
```

```
Q3 (75%): 7082.75 caracteres
```




```
Novo limiar científico definido (P35): Mínimo de 92 caracteres.
```



Filtragem de Conteúdo Relevante

Aplicamos os filtros baseados nos quartis calculados acima.

	repo	file1	file2	similarity	len1	len2	words1	words2
271	erxes/erxes	CLAUDE.md	CURSOR	0.000808	32955	1689	3989	249
270	erxes/erxes	AGENTS.md	CURSOR	0.001558	32979	1689	3985	249
453	NVIDIA/cccl	AGENTS.md	CLAUDE.md	0.001667	16468	328	2192	48
463	oxc-project/oxc	AGENTS.md	COPILOT	0.001933	13802	685	1662	103
39	cypress-io/cypress	AGENTS.md	CLAUDE.md	0.002498	11347	1463	1489	233
...	...	...	...	...	...	...	...	...
513	kubeovn/kube-ovn	AGENTS.md	CLAUDE.md	1.000000	2079	2079	309	309
652	jihong88/suneditor	CLAUDE.md	GEMINI.md	1.000000	1490	1490	177	177
112	forem/forem	CURSOR	COPILOT	1.000000	5293	5293	731	731
590	garmeeh/next-seo	AGENTS.md	CLAUDE.md	1.000000	4158	4158	627	627
10	gitlabhq/gitlabhq	AGENTS.md	CLAUDE.md	1.000000	1840	1840	254	254

262 rows × 8 columns

```
262 Resultados encontrados.
Existem 205 repositório com ao menos um par de arquivos de contexto de IA com semântica textual considerável
```

Definição das Classificações Semânticas

Para garantir a reprodutibilidade e clareza científica, definimos as categorias de análise da seguinte forma:

1. **Redundantes:** Os arquivos apresentam alto grau de sobreposição (ex: > 70%). As instruções são meras paráfrases ou cópias diretas, indicando que a multiplicidade serve apenas para compatibilidade de ferramentas, sem ganho de conteúdo.
2. **Complementares:** Os arquivos compartilham diretrizes globais (ex: stack), mas possuem especializações únicas para a ferramenta alvo (ex: regras de UI específicas para o Cursor vs regras de CLI para o Claude).
3. **Conflitantes:** Existem diretrizes que se contradizem diretamente (ex: padrões de indentação diferentes ou comandos de build distintos), criando ambiguidade para o agente de IA.
4. **Independentes:** Os arquivos tratam de domínios completamente distintos do projeto, com sobreposição próxima de zero.

Comparação semântica via LLM

Através do uso do google gemini ou um agente local, será realizada a leitura dos conteúdos dos arquivos e classificação da similaridade semântica dos mesmos.

```
Iniciando análise PROVISÓRIA de 30 pares de arquivos...
[1/30] [microsoft/vscode] AGENTS.md vs COPILOT: INDEPENDENTES (0%) - Aplicando os testes definidos no formato de saída, podemos concluir que esses arquivos são independe
[2/30] [microsoft/typescript] AGENTS.md vs COPILOT: COMPLEMENTARES (0%) - O conteúdo dos dois
```

```
arquivos pode ser considerado complementar ao invés de redundante ou conflitante
[3/30] [electron/electron] CLAUDE.md vs COPILOT: COMPLEMENTARES (0%) - Aplicando o 'TESTE'
definido, se deletarmos um arquivo, o outro ainda conteria a maioria das informa
[4/30] [gitlabhq/gitlabhq] AGENTS.md vs CLAUDE.md: REDUNDANTES (0%) - Os dois arquivos parecem
ser idênticos, compartilhando exatamente o mesmo conteúdo e instruções. Rea
[5/30] [JuliaLang/julia] AGENTS.md vs CLAUDE.md: INDEPENDENTES (0%) - A classificação
INDEPENDENTE é a mais apropriada porque se Arquivo B (CLAUDE.md) for removido, o con
[6/30] [pytorch/pytorch] CLAUDE.md vs COPILOT: COMPLEMENTARES (0%) - Baseado nos 'TESTES'
definidos acima e no conteúdo dos arquivos fornecidos, podemos concluir que Arq
[7/30] [home-assistant/core] AGENTS.md vs COPILOT: REDUNDANTES (0%) - Ao comparar os dois
arquivos, é evidente que eles compartilham o mesmo foco e conteúdo. Se você dele
[8/30] [mui/material-ui] AGENTS.md vs CLAUDE.md: INDEPENDENTES (0%) - Ao analisar os dois
arquivos, notamos que o ARQUIVO A (AGENTS.md) fornece um guia detalhado e especí
[9/30] [metabase/metabase] CLAUDE.md vs COPILOT: INDEPENDENTES (0%) - Os arquivos tratam de
domínios completamente distintos. O Arquivo A é centrado em ferramentas de des
[10/30] [compiler-explorer/compiler-explorer] CLAUDE.md vs COPILOT: INDEPENDENTES (0%) - A
classificação como INDEPENDENTES é justificada pelos seguintes elementos dos arquivos de contexto
[11/30] [vitessio/vitess] CLAUDE.md vs COPILOT: INDEPENDENTES (0%) - Os elementos semânticos dos
dois arquivos podem ser facilmente verificados e diferenciados. Arquivo
[12/30] [seleniumhq/selenium] AGENTS.md vs CLAUDE.md: INDEPENDENTES (0%) - Se você deletar o
Arquivo B, o Arquivo A continua 100% íntegro, útil e compreensível. O conteúdo do
[13/30] [seleniumhq/selenium] AGENTS.md vs COPILOT: INDEPENDENTES (0%) - Os dois arquivos tratam
de domínios completamente distintos. Arquivo A fornece uma visão geral compl
[14/30] [seleniumhq/selenium] CLAUDE.md vs COPILOT: COMPLEMENTARES (0%) - Os arquivos tratam de
um domínio semelhante, que se concentra na prática de boas práticas durante o
[15/30] [cypress-io/cypress] Falha ao baixar arquivos.
[16/30] [facebook/rocksdb] Falha ao baixar arquivos.
[17/30] [directus/directus] Falha ao baixar arquivos.
[18/30] [denoland/deno] Falha ao baixar arquivos.
[19/30] [remix-run/react-router] Falha ao baixar arquivos.
[20/30] [azure/azure-sdk-for-net] Falha ao baixar arquivos.
[21/30] [apereo/cas] Falha ao baixar arquivos.
[22/30] [automattic/wp-calypso] Falha ao baixar arquivos.
[23/30] [conda/conda] Falha ao baixar arquivos.
[24/30] [conda/conda] Falha ao baixar arquivos.
[25/30] [conda/conda] Falha ao baixar arquivos.
[26/30] [apache/shardingsphere] Falha ao baixar arquivos.
[27/30] [opf/openproject] Falha ao baixar arquivos.
[28/30] [azure/azure-sdk-for-python] Falha ao baixar arquivos.
[29/30] [azure/azure-sdk-for-java] Falha ao baixar arquivos.
[30/30] [mochajs/mocha] Falha ao baixar arquivos.

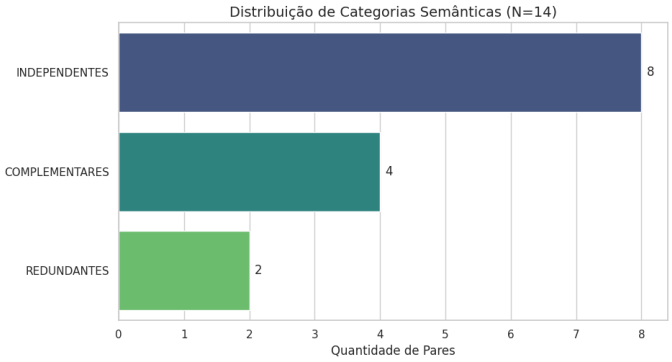
Análise provisória concluída!
```

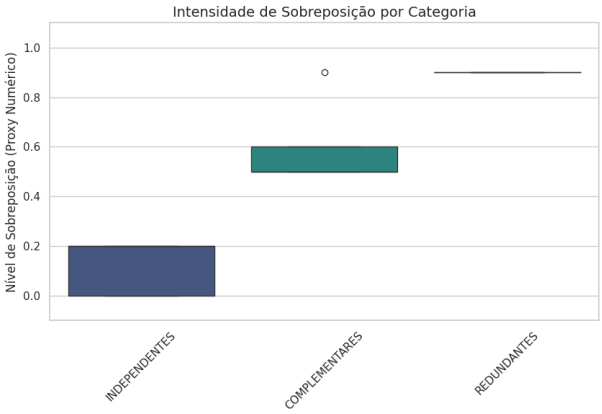
Análise Estatística e Visualização (H1)

Nesta seção, validamos a **Hipótese 1** analisando a distribuição das métricas de sobreposição e conflito.

Visualização dos Resultados (Hipótese 1)

Nesta seção, apresentamos a distribuição das classificações semânticas e a dispersão do overlap global para validar a redundância ou especialização dos arquivos.





sobreposicao_cat	ALTA	BAIXA	MEDIA	ZERO
classificacao_final				
COMPLEMENTARES	1	0	3	0
INDEPENDENTES	0	5	0	3
REDUNDANTES	2	0	0	0

3. RQ02 — Estrutura e Classificação de Conteúdo dos Arquivos de Contexto

Fontes: notebooks/4-structure_analysis_study.ipynb e 5-ai-file-classification-study.ipynb — amostra de 266 repositórios / 8.129 cabeçalhos (Top 1000, 23-03-2026)

> **Contexto:** esta é a análise de conteúdo/estrutura (chamada "RQ2" no registro histórico do projeto). Examina a hierarquia dos cabeçalhos Markdown extraídos dos arquivos de contexto, os termos mais recorrentes, e depois classifica cada cabeçalho em categorias temáticas (ex.: "Testing Instructions", "Architecture / Project Structure", "Code Conventions") usando um dicionário de palavras-chave, comparando a distribuição de categorias entre os diferentes tipos de arquivo (AGENTS.md, CLAUDE.md, COPILOT, GEMINI.md, CURSOR). **Nota:** o usuário está complementando esta RQ com uma validação manual feita em planilha própria (fora deste repositório), que será fornecida separadamente.

Estudo da estrutura dos arquivos de IA extraídos

Este notebook tem como objetivo analisar a estrutura resultante da extração de cabeçalhos dos arquivos de contexto de IA (`AGENTS.md`, `CLAUDE.md`, etc.), gerando estatísticas sobre a hierarquia e os termos mais comuns antes da classificação semântica.

Importação de bibliotecas e configuração

Carregamento dos dados

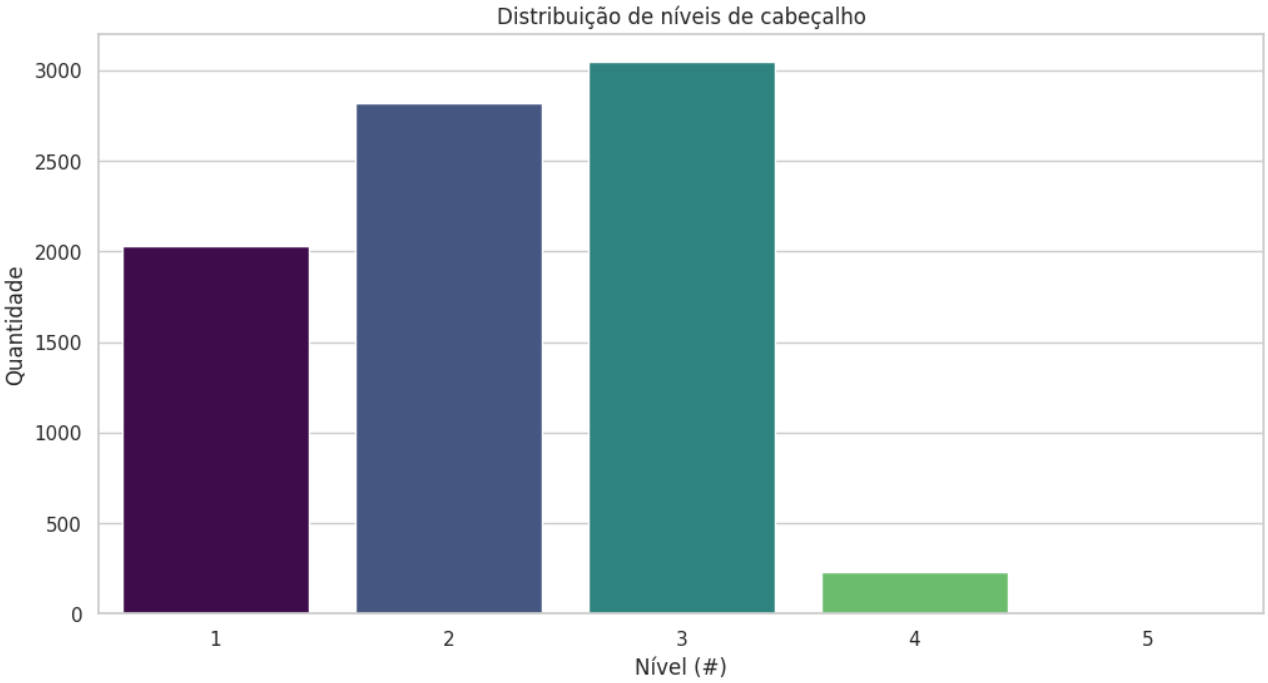
O arquivo analisado é o `structure_analysis.csv`, gerado pelo script `extract_content_structure.py`.

```
Total de registros: 8129
Total de repositórios únicos: 266
```

	repo	file_type	level	title_original	title_normalized
0	elastic/elasticsearch	AGENTS.md	1	Elasticsearch	elasticsearch
1	elastic/elasticsearch	AGENTS.md	2	Toolchain Snapshot	toolchain snapshot
2	elastic/elasticsearch	AGENTS.md	2	Build & Run Commands	build run commands
3	elastic/elasticsearch	AGENTS.md	2	Verification & Lint Tasks	verification lint tasks
4	elastic/elasticsearch	AGENTS.md	2	Project Structure	project structure

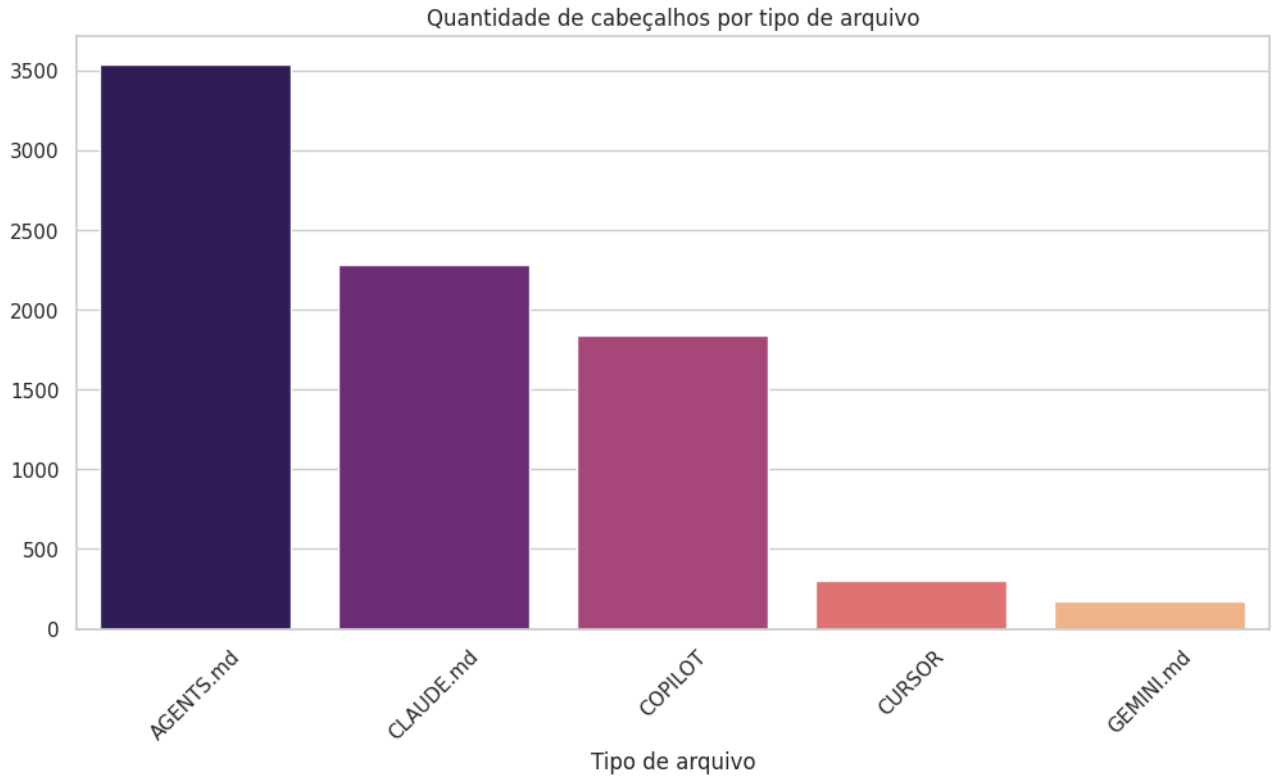
Análise de hierarquia

Verifica a distribuição dos níveis de cabeçalho (`#`, `##`, `###`). Níveis mais altos (2 e 3) geralmente indicam instruções mais detalhadas.

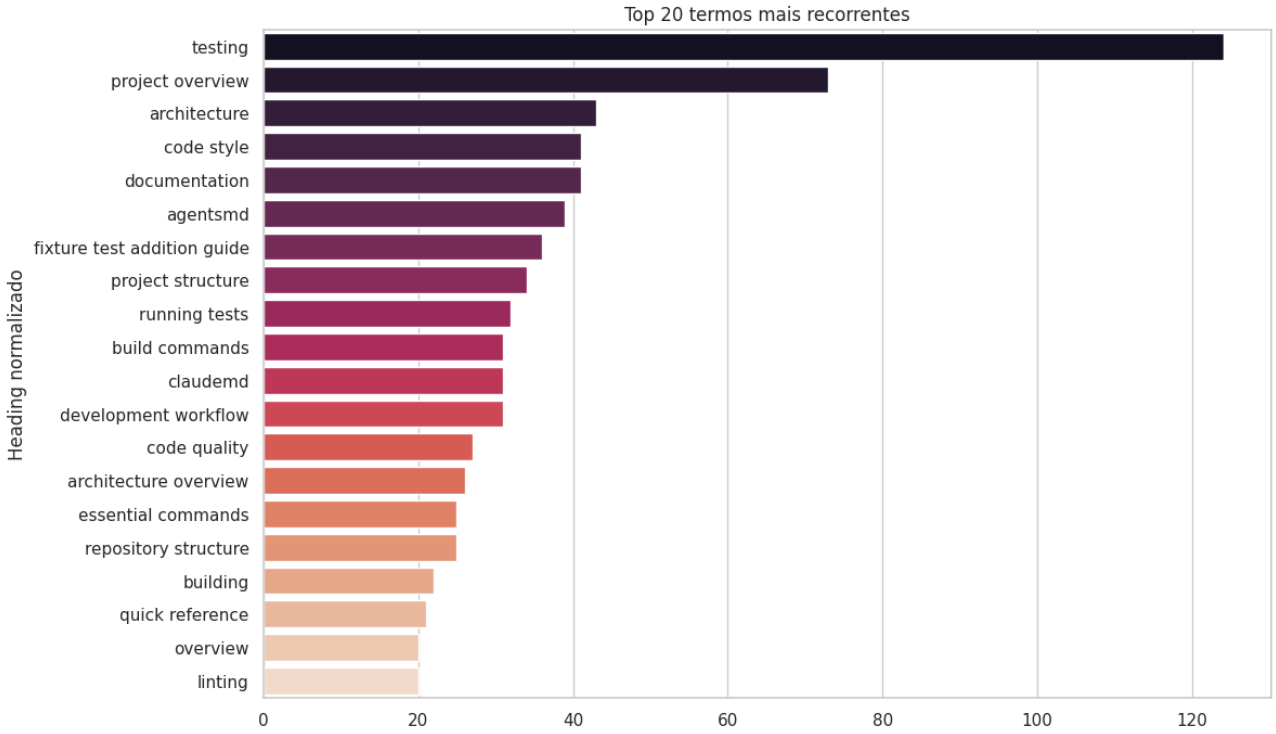



```
Porcentagem por nível:
level
3    37.458482
2    34.653709
1    24.972321
4     2.866281
5     0.049207
Name: proportion, dtype: float64
```

4. Distribuição por tipo de arquivo



Termos mais frequentes (headings puros)



Estudo da classificação do conteúdo de arquivos de contexto de IA

Importação e configuração

Carregamento dos dados

```
Total de cabeçalhos carregados: 8129
Arquivo utilizado: ../data/content_analysis/structure_analysis_classified.csv
```

Definição do dicionário e função de classificação

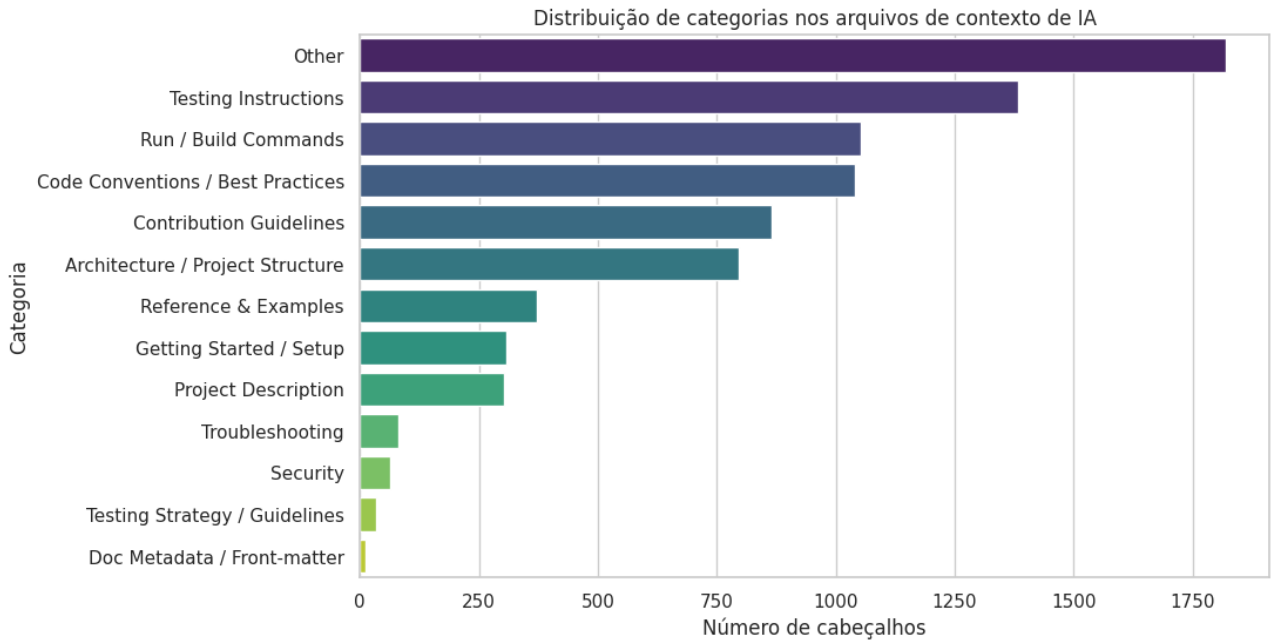
Aplicando classificação

```
Exemplos de classificação:
```

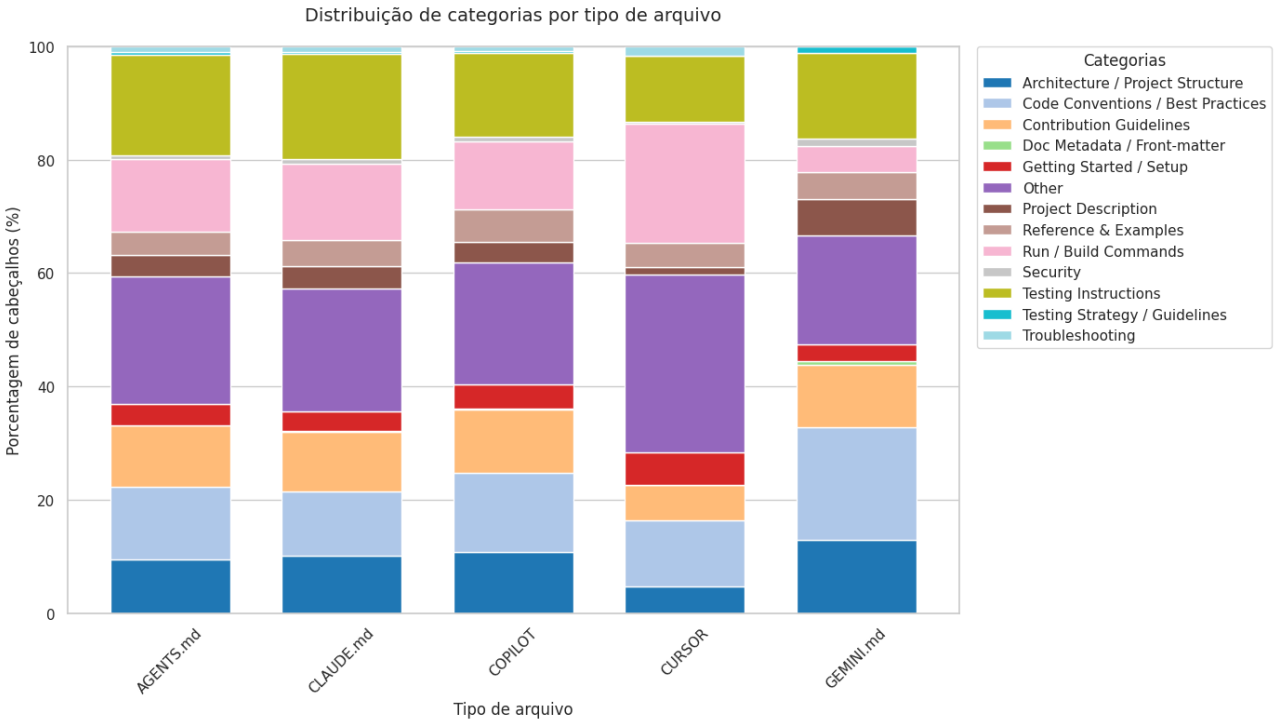
	title_original	category
4965	Testing	Testing Instructions
5075	Common Extension Points	Other
4009	Rust dependencies	Getting Started / Setup
6969	Translation System	Other

	title_original	category
2992	General Guidelines	Code Conventions / Best Practices
1729	Branches	Contribution Guidelines
4329	Coding conventions and hygiene	Code Conventions / Best Practices
5494	Skills	Project Description
3144	Commit Messages	Contribution Guidelines
4567	Trilium Notes - AI Coding Agent Instructions	Project Description

Distribuição de categorias



Categorias por tipo de arquivo



4. Validação de Fidelidade das Instruções de Teste (apoio à RQ02)

Fonte: notebooks/6.1-test-validity-checker.ipynb

> **Contexto:** estudo de apoio à RQ02 que audita se os frameworks de teste mencionados no texto dos arquivos de contexto (ex.: "use pytest", "rode com Jest") realmente têm suporte técnico comprovável no repositório (arquivos de configuração como `pytest.ini`, `jest.config`, etc.). Gera um "índice de alinhamento" (fidelidade) e uma lista de frameworks citados sem lastro técnico ("drift"). Relevante para discutir a qualidade/confiabilidade do conteúdo além da sua mera presença estrutural.

Analise o alinhamento de contexto - Testes

Importação e configuração

Carregamento dos dados

```
Index(['repo', 'file_type', 'testing_sections', 'file_tree'], dtype='str')
```

```
repo
```

```
          Homebrew/homebrew-core
file_type




                      AGENTS.md
testing_sections
```

```
                                          [{'heading': 'Test block:', 'level': 4,
'content': '- Test MUST verify actual functionality:
  - execute the installed binary or library
  - include at least one assertion beyond `--version` or `--help` or similar
  - validate the build produced a working result,
  - For libraries: compile and link sample code
- `testpath` returns the working directory for tests in test block
- Test should not cover every possible edge case nor be so minimal that it doesn't actually
verify the software.'}, {'heading': 'Run tests', 'level': 1, 'content': 'brew test <formula>'}]
file_tree           [.github, .github/ISSUE_TEMPLATE.md, .github/ISSUE_TEMPLATE, .github/
ISSUE_TEMPLATE/bug.yml, .github/ISSUE_TEMPLATE/config.yml, .github/
PULL_REQUEST_TEMPLATE.md, .github/actionlint.yaml, .github/codeql, .github/codeql/
extensions, .github/codeql/extensions/homebrew-actions.yml, .github/dependabot.yml, .github/
workflows, .github/workflows/actionlint.yml, .github/workflows/autobump.yml, .github/workflows/
automerge-from-merge-queue.yml, .github/workflows/automerge-triggers.yml, .github/workflows/
automerge.yml, .github/workflows/cache.yml, .github/workflows/clean-up-closed-prs.yml, .github/
workflows/create-replacement-pr.yml, .github/workflows/dispatch-build-bottle.yml, .github/
workflows/dispatch-rebottle.yml, .github/workflows/manage-pull-request-labels.yml, .github/
workflows/publish-commit-bottles.yml, .github/workflows/recreate-linux-runners.yml, .github/
workflows/remove-disabled-packages.yml, .github/workflows/remove-unused-patches.yml, .github/
workflows/scheduled.yml, .github/workflows/scripts, .github/workflows/scripts/check-
labels.js, .github/workflows/stale-issues.yml, .github/workflows/tests.yml, .github/workflows/
triage-ci.yml, .github/workflows/triage.yml, .github/zizmor.yml, .rubocop.yml, .ruby-version,
AGENTS.md, Abstract, Abstract/portable-formula.rb, Aliases, Aliases/0install, Aliases/0mq,
Aliases/2ms, Aliases/2ping, Aliases/3mux, Aliases/4store, Aliases/64tass, Aliases/6tunnel,
Aliases/7-zip, Aliases/7zip, Aliases/actor-framework, Aliases/ag, Aliases/alut, Aliases/
ansible@13, Aliases/ant@1.10, Aliases/apache-activemq, Aliases/apache-flink@2, Aliases/apache-
fop, Aliases/apache-httpd, Aliases/apache2, Aliases/arpack-ng, Aliases/assimp@6, Aliases/
atkmm@2.36, Aliases/autoconf@2.73, Aliases/awscli@2, Aliases/awsebcli, Aliases/az, Aliases/azd,
Aliases/bal, Aliases/bash-completion@1, Aliases/basisu, Aliases/bats, Aliases/bazel@9, Aliases/
berkeley-db@18, Aliases/bison@3.8, Aliases/bjam, Aliases/boehmgc, Aliases/boost-jam, Aliases/
boost@1.90, Aliases/boot2docker-cli, Aliases/botan@3, Aliases/brz, Aliases/cairomm@1.18,
Aliases/cassandra@5.0, Aliases/ck, Aliases/clang-format@22, Aliases/clasp, Aliases/conan@2,
Aliases/cowthink, Aliases/cpanm, Aliases/crypto++, Aliases/ctags-exuberant, Aliases/db, Aliases/
dejagnu, Aliases/delta, Aliases/dlv, Aliases/dotnet@10, Aliases/dupeseek, Aliases/eigen@5, ...]
Name: 0, dtype: object
```

Exemplo de Inspeção Detalhada

Use a função `inspect_repo('nome/repo')` para ler o conteúdo completo de um repositório específico de forma legível.

1. Definição de Marcadores de Frameworks

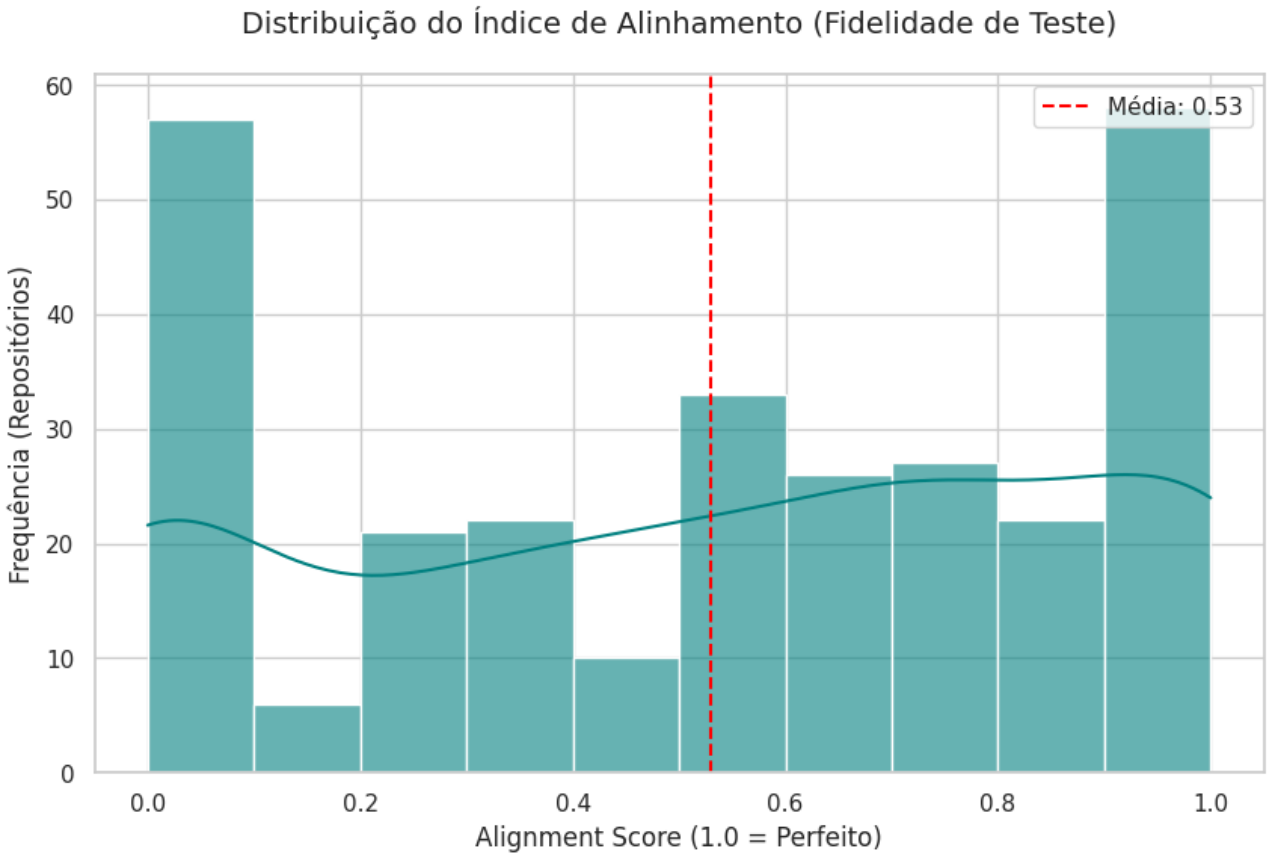
Mapeamos palavras-chave de frameworks para arquivos de configuração que comprovam sua existência.

2. Auditoria de Fidelidade via Pandas

Utilizamos operações vetorizadas e `apply` para validar cada repositório contra sua árvore de arquivos.

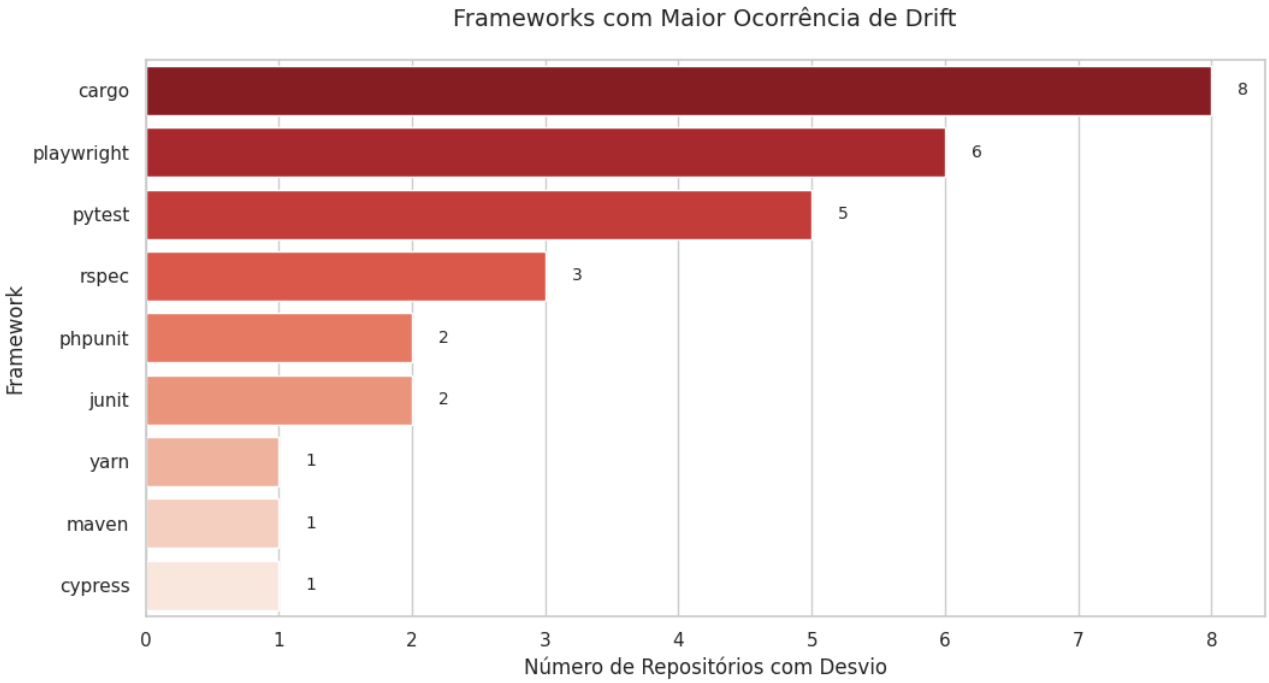
	repo	file_type	fw_mentions	fw_matches	fw_drifts	fw_drift_list	path_mentions	path_matches	path_drifts	align
0	Homebrew/homebrew-core	AGENTS.md	0	0	0		0	0	0	0.000
1	JuliaLang/julia	AGENTS.md	0	0	0		1	1	0	1.000
2	StarRocks/starrocks	AGENTS.md	0	0	0		15	14	1	0.933
3	StarRocks/starrocks	CLAUDE.md	0	0	0		15	14	1	0.933
4	TriliumNext/trilium	CLAUDE.md	3	3	0		0	0	0	1.000

3. Visualização do Alinhamento de Contexto



4. Análise de Drift por Framework

Identificamos quais ferramentas são citadas com frequência sem terem suporte técnico real.



5. Comparação Temporal de Adesão (Notebook Ainda Não Executado)

Fonte: notebooks/analysis_comparison.ipynb

> **Aviso:** este notebook ainda não foi executado neste repositório (nenhuma saída/gráfico disponível) — está estruturado para comparar snapshots de datas diferentes (Ago/2025, Mar/2026, Abr/2026) e medir evolução da adesão ao longo do tempo, mas as células de conclusão ainda contêm placeholders ("[Descreva aqui a tendência observada]"). Incluído aqui apenas para registrar que essa análise (potencial RQ3 / evolução histórica) está planejada, mas pendente.

Comparativo temporal de adesão de arquivos de contexto de IA

Importando bibliotecas

Carregando dados

Análise dos dados

Evolução da adesão por tipo de arquivo

Comparação direta entre a primeira e a última coleta

Conclusões da análise temporal

- **Tendência**: [Descreva aqui a tendência observada]
- **Crescimento**: [Identifique qual formato teve maior crescimento]
- **Estabilidade**: [Note se algum formato se manteve estável]